

Clasificación multiclase

Aprendizaje Automático

A la hora de resolver un problema de clasificación, muchos de los modelos de aprendizaje automático existentes permiten solamente separar dos clases, que se suelen denominar “positivo” y “negativo”. Los patrones “positivos” suelen ser los relacionados con aquello que se quiere detectar, como enfermedad, alarma, o un tipo de objeto en una imagen. Los patrones “negativos” suelen caracterizarse por la ausencia de esta característica que tienen los positivos. Para desarrollar una RNA que clasifique en dos clases, se necesita una única neurona en la capa de salida, con función de transferencia sigmoidea logarítmica (u otra similar), de tal forma que la salida de la RNA estará entre 0 y 1, y puede interpretarse como la certeza que tiene la RNA en clasificar un patrón como “positivo”. La clasificación en “negativo” o “positivo” se realiza de una forma sencilla, aplicando un umbral que suele estar en 0.5, aunque se puede cambiar.

Sin embargo, en muchas ocasiones se desea desarrollar un sistema que sea capaz de clasificar en más de dos clases. Un ejemplo sencillo es un sistema que quiera clasificar una imagen según si es un perro, gato o ratón, u otro tipo de animal. En este caso, se desea desarrollar un sistema de clasificación en 4 clases: “perro”/”gato”/”ratón”/”otro”. Si se desea entrenar una RNA para distinguir entre estos 3 animales, se necesita una neurona de salida para cada clase, incluyendo la clase “otro” (4 neuronas de salida en total).

En este esquema, como se ha realizado en prácticas anteriores, cuando hay más de dos clases generalmente se usa una codificación llamada en inglés *one-hot-encoding*, que se basa en, para cada patrón, crear un valor booleano con un valor correspondiente a cada clase, de tal forma que un cada valor booleano será igual a 1 si ese patrón pertenece a esa clase, y 0 en caso contrario. Al entrenar una RNA con este esquema, cada neurona de salida puede entenderse como un modelo especializado en clasificar en una clase determinada. En este tipo de redes se suele usar una función de transferencia lineal en la capa de salida, con lo que salidas negativas indican que esa neurona no clasifica el patrón en esa clase (es decir, desde el punto de vista de esa clase lo clasifica como “negativo”), y salidas positivas indican que una neurona clasifica el patrón como esa clase (es decir, desde el punto de vista de esa clase lo clasifica como “positivo”). El valor absoluto de la salida de una neurona indica la seguridad de esa neurona en la clasificación. Finalmente, la función *softmax* recibe esos valores de clasificación y los transforma de tal manera que estén entre 0 y 1, y sumen 1, interpretándose como la probabilidad de pertenencia a cada clase. El patrón se clasificará en aquella clase

cuyo valor de salida sea más alto. La función *softmax* se define de la siguiente manera:

$$\text{softmax}(y_i) = \frac{e^{y_i}}{\sum_j e^{y_j}}$$

donde y^i es la salida de la neurona i . Por ejemplo, en un problema de clasificación de 3 clases si se tiene salidas de las 3 neuronas de $[2, 1, 0.2]$, en este caso las 3 neuronas clasificarían las entradas como pertenecientes a sus respectivas clases, aunque la primera con mucha mayor certidumbre. Al pasar la función *softmax*, las probabilidades respectivas serán $[0.65, 0.24, 0.11]$, con lo que se clasificará como la primera clase.

De esta forma, la función *softmax* convierte los valores reales que emiten las salidas de las neuronas de salida en valores de probabilidad, haciendo que cuanto más negativo sea un valor (más certeza de no pertenencia a esa clase), este se transforme en un valor más próximo a 0, y cuanto más positivo sea un valor (más certeza de pertenencia a esa clase), este se transforme en un valor más próximo a 1. Como se indicó antes, la suma de valores o probabilidades de la última capa será igual a 1. Por este hecho, es necesaria una cuarta clase especial “otro” en el ejemplo anterior, y en general una clase extra en el caso de que, con varias clases, un patrón pueda no pertenecer a ninguna de ellas.

- ¿Por qué es necesaria esta clase extra al usar la función *softmax*?
 - Ayuda: escribir en Julia `softmax([-1, -1, -0.2])`, e interpretar las entradas (¿qué representa el vector $[-1, -1, -0.2]$ y cómo se interpreta?) y las salidas de la función (¿cuánto suman los valores? ¿qué dice cada una?)
 - Para utilizar esa función, importarla de la librería *Flux*.
- ¿Podría no ser necesaria crear la clase adicional? ¿Qué modificación habría que hacer en la RNA? ¿Cómo se interpretaría la salida? ¿Cómo se generaría la clase de salida en función de las salidas de las neuronas de salida?
- En general, ¿cómo tiene que ser la salida de un modelo para que no se necesite esta cuarta clase?
- ¿El modelo kNN necesita esta cuarta clase?
- ¿Cuántas clases serían necesarias si una RNA quisiera reconocer esos 3 tipos de animales, y, si no es uno de ellos, decir si es un animal o no? ¿Y si el modelo es un

kNN?

Por lo tanto, al tener más de dos clases, ya no se aplica el esquema “positivo”/“negativo”. El problema en estos casos es que muchos de los modelos de aprendizaje automático solamente son capaces de separar dos clases, con lo que, en principio, no podrían utilizarse. Un ejemplo de este tipo de sistemas son las Máquinas de Soporte Vectorial (SVM), que se ven con más profundidad en clase de teoría. Sobre este modelo se han realizado modificaciones en su formulación para permitir clasificaciones multiclase; sin embargo, en la práctica no suelen usarse, y en su lugar se suele emplear una estrategia que permite usar las SVM binarias para clasificar en varias clases.

Existen dos grandes estrategias para “convertir” problemas multiclase en problemas de clasificación binaria. Estas estrategias se llaman “uno contra uno” o “uno contra todos”. En clase de teoría se explican ambas, pero dado que “uno contra todos” es mucho más utilizado, en prácticas se utilizará esta estrategia.

La estrategia “uno contra todos” se basa en, si se tiene un problema de clasificación de L clases, generar L problemas de clasificación binaria, uno por clase. En el i -ésimo problema, la clase i debe ser separada del resto, es decir, los patrones que pertenezcan a esa clase serán considerados “positivos”, y los que no pertenezcan a ella serán considerados “negativos”. Siguiendo con el ejemplo anterior de los animales, habría que resolver 3 problemas de clasificación distintos: uno para clasificar “perro”/“no perro”, otro para clasificar “gato”/“no gato”, y otro para clasificar “ratón”/“no ratón”. Se entrenarían, por tanto, 3 clasificadores con las mismas entradas pero con salidas deseadas distintas para cada problema.

- En la descripción anterior, para estos 3 animales se utilizaron 4 clases, incluyendo la clase “otro”. ¿Por qué no se entrena un clasificador para esta clase?

Una vez entrenados, para evaluar un nuevo patrón este se aplica en los 3 clasificadores y, en función de la salida, se toma una decisión. Si sólo uno de los sistemas tiene salida positiva, o ninguno de los tres lo clasifica como positivo, la decisión está clara. Sin embargo, en alguna ocasión más de un clasificador dará una salida positiva para un mismo patrón. Por suerte, muchos clasificadores, además de emitir una salida en forma de clasificación (en este caso “positivo”/“negativo”), dan información acerca del nivel de certidumbre o seguridad que tienen de que ese patrón sea clasificado como “positivo”. Si más de un clasificador clasifica al patrón como positivo, se clasifica en la clase correspondiente al clasificador que tenga una mayor seguridad en su clasificación.

- ¿Se podrían usar las salidas de estos 3 clasificadores como entrada a la función *softmax*? ¿Qué consecuencias tendría?
- En general, cuando hay L clases y la posibilidad de que un patrón no pertenezca a ninguna de ellas, ¿cuál es el impacto de usar la función *softmax* en las salidas? ¿En qué casos se podría usar? ¿Por qué?
- La función *softmax* es útil para conseguir un valor de *loss* que permita entrenar la RNA. Sin embargo, si no se usara, en el ejemplo anterior de los animales, ¿sería necesaria la cuarta clase “otro”?

Finalmente, es necesario tener en cuenta otra posibilidad distinta a la hora de asignar los patrones a las clases. Hasta el momento, y en la mayoría de las situaciones, las clases consideradas son mutuamente excluyentes, es decir, en el ejemplo anterior, un animal o bien es perro, o bien es gato, o bien es ratón, o bien ninguna de las 3, pero no puede ser de varias clases a la vez. Este es el caso más común, pero en ocasiones algún problema tendrá clases que no son mutuamente excluyentes. Por ejemplo, al clasificar sonidos de animales según el animal que los emita, puede ocurrir que en un sonido se mezclen varios animales. En estos casos, el esquema utilizado de usar una función de transferencia lineal en la última capa junto con la función *softmax* no funcionaría, puesto que, de forma natural, la suma de las probabilidades de pertenencia a las clases puede ser mayor que 1 (puede pertenecer a varias clases a la vez). Para estos casos, el esquema que puede utilizarse para entrenar RR.NN.AA. es usar funciones de transferencia sigmoideas logarítmicas en la última capa (en lugar de lineales), que dan una salida entre 0 y 1, y no realizar transformación mediante la función *softmax*. De esta manera, la salida final de cada neurona de salida es independiente del resto de neuronas de salida, y más de una puede tomar valores cercanos a 1. La salida de cada neurona nuevamente se interpretaría como la probabilidad de pertenencia a esa clase, pero en este caso la suma de las probabilidades no tiene que ser 1 (son independientes). El no aplicar la función *softmax* tiene dos ventajas: la primera, ya mencionada, es que permite la clasificación en clases no mutuamente excluyentes; la segunda es que al no usar esta función ya no se necesita una clase adicional (“otro” en el ejemplo anterior) para los casos en que un conjunto de entradas pueda no pertenecer a alguna de las clases dadas.

- ¿Por qué ya no se necesita esta clase extra?

Ante un conjunto de entradas, como siempre, este se clasifica en la clase cuya neurona de salida haya mostrado una mayor seguridad. Este esquema de salidas no mutuamente

excluyentes es similar al esquema “uno contra todos”, en el que se entrenan en paralelo un clasificador por clase. Los clasificadores son independientes y la clase final es la de aquel clasificador que tenga una mayor certeza de pertenencia a esa clase. Si todos los clasificadores devuelven como clasificación “negativo” y no existe la posibilidad de no pertenencia a ninguna clase, se clasifica en la clase correspondiente al clasificador que tenga la menor certeza de que es negativo. Si todos los clasificadores devuelven como clasificación “negativo” y sí existe la posibilidad de no pertenencia a ninguna clase, sencillamente se clasifica como “otro”.

La siguiente tabla muestra un resumen de las situaciones a la hora de usar una RNA para resolver un problema de clasificación. Tened en cuenta que en el caso de clasificación binaria no se contempla la posibilidad de que un conjunto de entradas no pertenezcan a ninguna clase, puesto que en este caso se estaría en clasificación multiclase.

		¿Se añade clase extra si puede no pertenecerse a ninguna de las dadas?	Función de transferencia capa de salida	Intervalo salida de la neurona de salida	Función que se aplica a las salidas (capa adicional)	Intervalo salida final	¿En qué clase se clasifica?
Clasificación binaria		-	sigmoidal logarítmica	[0, 1]	-	[0, 1]	“negativo”/“positivo” según la salida mayor o igual a un umbral (0.5 para salidas en [0, 1])
Multiclase	Clases mutuamente excluyentes	Sí	lineal	$[-\infty, \infty]$	<i>softmax</i>	[0, 1]	Clase cuya salida tiene el valor más próximo a 1
	Clases no mutuamente excluyentes	No	sigmoidal logarítmica	[0, 1]	-	[0, 1]	Clases con salida mayor o igual a un umbral (0.5 para salidas en [0, 1]) (podrían ser varias, o ninguna)

En el caso de usar una estrategia “uno contra todos”, esta sería similar a la última fila, excepto por el hecho de que el intervalo no sería necesariamente [0, 1], sino que estaría condicionado por el modelo que se usase, y, por lo tanto, el umbral también. Por ejemplo, un SVM emite salidas entre $-\infty$ y $+\infty$, con lo que el umbral típico está en el 0.

Otro factor a tener en cuenta al tratar problemas multiclase es la métrica escogida. La mayoría de las métricas estudiadas (VPP, sensibilidad, etc.) corresponden a problemas de clasificación binaria. Cuando el número de clases es superior a 2, estas métricas se siguen pudiendo usar; sin embargo, su uso es ligeramente distinto.

Cuando el número de clases es superior a dos, las métricas VPP, VPN, sensibilidad y especificidad se pueden calcular de forma separada para cada clase. De esta forma, para una clase concreta los patrones positivos son los clasificados en esa clase, y los negativos son los clasificados en cualquiera de las otras clases. Una asignación similar se puede construir con los patrones que pertenecen a esa clase y los que pertenecen al resto de clases. De esta forma, desde el punto de vista exclusivo de esa clase, se puede calcular VP, VN, FP y FN, y a partir de ellos los valores de sensibilidad, especificidad, VPP y VPN para esa clase en concreto, y, finalmente, el valor de F_1 -score. Esta forma de tratar las clases de forma separada es parecida al desarrollo de varios clasificadores en la estrategia “uno contra todos” (en el caso de entrenar clasificadores binarios que no permitan realizar clasificación multiclase). Una vez calculadas estos valores, estos se pueden combinar en uno único que será el usado para valorar el rendimiento del clasificador. Para esto, existen 3 estrategias: *macro*, *weighted* y *micro*, de las cuales en prácticas usaremos solamente las dos primeras:

- *Macro*. En esta estrategia, se calculan las métricas como sensibilidad, VPP o F_1 -score como una media aritmética de las métricas correspondientes a cada clase. Al ser media aritmética, no tiene en cuenta el posible desbalanceo entre clases.
- *Weighted*. En esta estrategia, se calculan las métricas como sensibilidad, VPP o F_1 -score como una media de las métricas correspondientes a cada clase ponderado por el número de patrones que pertenecen (salida deseada) a cada clase. Por lo tanto, es adecuada cuando las clases están desbalanceadas.
- *Micro*. Se calcula el número de VP, FN y FP de forma global. Cuando las clases no son mutuamente excluyentes, el resultado tanto de micro-sensibilidad, micro-VPP o *micro- F_1 -score* es idéntico al de la precisión. Por lo tanto, esta métrica es de utilidad cuando existen clases mutuamente excluyentes.

En esta práctica, se pide:

- Desarrollar el código necesario para realizar una estrategia “uno contra todos”. A pesar de que no es necesario desarrollarlo para realizar multiclase con RR.NN.AA., se utilizará en futuras prácticas. Una forma sencilla de realizar esto es la siguiente:
 - Calcular el número de clases y crear una matriz bidimensional de valores reales, con tantas filas como patrones y tantas columnas como clases.

```
outputs = Array{Float32,2}(undef, numInstances, numClasses);
```

- Realizar un bucle que itere sobre cada clase. En el interior de este bucle, se crean las salidas deseadas correspondientes a esa clase y se entrena el modelo correspondiente con esas entradas y las nuevas salidas deseadas correspondientes a esa clase. Es decir, se crea un modelo por clase que indica la pertenencia o no a esa clase. Posteriormente, ese modelo se aplica a las entradas (de entrenamiento y/o test) para calcular las salidas, que se copiarán en la matriz previamente creada. El código sería similar al siguiente, en el que se ha usado una supuesta función *fit* que entrenaría un modelo de clasificación binario:

```
for numClass in 1:numClasses

    model = fit(inputs, targets[:,numClass]);

    outputs[:,numClass] .= model(inputs);

end;
```

- En este código se ha supuesto también que *targets* es de tipo *AbstractArray{Bool,2}*. ¿Cómo se podría hacer si fuese un vector con las clases de cualquier tipo (por ejemplo, que contenga ["coche", 17, "moto"]), es decir, de tipo *Array{Any,1}*?
- Una vez se tienen las salidas en la matriz *outputs*, para cada fila (cada patrón) se toma el valor mayor. Es decir, se toma la clase de aquel modelo que tenga una mayor certidumbre de que pertenece a "su" clase.
 - Opcionalmente, se puede pasar la función *softmax*. El resultado final es el mismo: se tomará la clase con mayor valor. Sin embargo, la función *softmax* permite interpretar las salidas como la probabilidad de pertenencia a cada clase.

Un problema en el uso de *softmax* es que está preparada para su uso con RR.NN.AA., por lo que espera que cada patrón esté en una fila. Para solucionarlo, habría que trasponer la matriz *outputs* y trasponer de nuevo el resultado, de la siguiente manera:

```
outputs = softmax(outputs')';
```

- Para tomar la salida mayor de cada clase, se puede realizar de forma similar a la forma en la que en la práctica 2 se calculaba la precisión en el caso de tener más de 2 clases y los patrones dispuestos en fila, con un código similar al siguiente:

```
vmax = maximum(outputs, dims=2);
```

```
outputs = (outputs .== vmax);
```

- Esta última línea puede presentar problemas en caso de que varios modelos generen la misma salida, ¿dónde estaría el problema? ¿cómo se solucionaría?

De esta forma, se tiene una matriz de valores booleanos *outputs* con la clase a la que pertenece cada patrón, que se puede utilizar para comparar con la matriz *targets* para calcular las distintas métricas.

- Desarrollar una función llamada *confusionMatrix* (el mismo nombre que en la práctica anterior) que permita devolver los valores de las métricas adaptadas a la condición de tener más de dos clases. Para ello, incluir un parámetro adicional que permita calcularlas de las formas *macro* y *weighted*.

Esta función debería recibir dos matrices: salidas del modelo (*outputs*) y salidas deseadas (*targets*), ambas de elementos booleanos y dimensión 2, con cada patrón en una fila y cada clase en una columna. Lo primero que debería hacer esta función es comprobar que el número de columnas de ambas matrices es igual y es distinto de 2. Para el caso de que tengan una sola columna, se toman esas columnas como vectores y se llama a la función *confusionMatrix* desarrollada en la práctica anterior.

- ¿Por qué no son válidas las matrices de dos columnas?

Si ambas matrices tienen más de dos columnas, se pueden ejecutar los siguientes pasos:

- Reservar memoria para los vectores de sensibilidad, especificidad, VPP, VPN y F_1 , con un valor por clase, inicialmente iguales a 0. Para realizar esto, se puede usar la función *zeros*.

- Iterar para cada clase, y, si hay patrones en esa clase, realizar una llamada a la función *confusionMatrix* de la práctica anterior pasando como vectores las columnas correspondientes a la clase de esa iteración de las matrices *outputs* y *targets*. Asignar el resultado en el elemento correspondiente de los vectores de sensibilidad, especificidad, VPP, VPN y F_1 .
- Reservar memoria para la matriz de confusión.
- Hacer un bucle doble en el que ambos bucles iteren sobre las clases, para ir rellenando todas las celdas de la matriz de confusión.
- Unir los valores que se tienen de sensibilidad, especificidad, VPP, VPN y F_1 para cada clase en un único valor usando la estrategia *macro* o *weighted* según se haya especificado en el argumento de entrada.
- Finalmente, calcular el valor de precisión con la función *accuracy* desarrollada en una práctica anterior, y a partir de este valor calcular la tasa de error.
- Desarrollar otra función llamada *confusionMatrix* en la que el primer parámetro *outputs* sea de tipo *AbstractArray{<:Real,2}*, y *targets* sea de tipo *AbstractArray{Bool,2}* (el mismo que antes). Lo que debería hacer esta función es convertir el primer parámetro a una matriz de valores booleanos (mediante la función *classifyOutputs*) y llamar a la función anterior.
- Sobrecargar esta función una vez más desarrollando otra del mismo nombre que realice la misma tarea, pero esta vez tome como entradas dos vectores (*targets* y *outputs*) de la misma longitud, cuyos elementos sean de cualquier tipo (es decir, que sean de tipo *AbstractArray{<:Any}*), además del parámetro adicional que permita calcular las métricas de las formas *macro* y *weighted*. Los elementos de estos vectores representan las clases, representados de distintas formas. Por ejemplo, las clases pueden ser [*“perro”*, *“gato”*, 3].

Como es obvio, es necesario que todas las clases de salida (vector *outputs*) estén incluidas en las clases de las salidas deseadas (vector *targets*). Incluir, por tanto, una línea de programación defensiva que asegure esto.

- Escribir esta línea sin ningún tipo de bucle. Para ello, puede ser útil consultar las funciones *all*, *in* y *unique*. Al final de esta práctica se da la solución de cómo

realizar esta línea.

- Como se verá en la práctica siguiente, esta línea en realidad no debería estar, puesto que es posible que se emita una salida que no esté entre las salidas deseadas. Esta línea es otro ejemplo de un pequeño ejercicio para practicar programación vectorial, pero una vez hecha la práctica debería ser temporalmente eliminada. En la siguiente práctica se excluye la posibilidad de que esto ocurra al dividir los patrones de una forma estratificada, así que esta línea se puede volver a incluir.
- ¿Cómo es posible que se emita una salida que no esté entre las salidas deseadas? ¿En qué casos puede ocurrir esto?

Para realizar esta función, sería necesario en primer lugar tomar las posibles clases tanto de *outputs* como de *targets* mediante la función *unique*. Una vez hecho esto, se codificarán ambas matrices, *outputs* y *targets*, mediante una llamada a la función *oneHotEncoding* pasando como argumento este vector de clases recién calculado. Con el resultado de estas dos codificaciones, se puede llamar a la función *confusionMatrix*.

- Es importante que se calcule primer el vector de clases y se pase este en ambas llamadas de codificación. ¿Qué podría ocurrir si no se hace de esta manera?

Aprende Julia:

La línea de programación defensiva que permite asegurarse de que todas las clases del vector de salidas están incluidas en el vector de salidas deseadas es la siguiente:

```
@assert(all([in(output, unique(targets)) for output in outputs]))
```